

퍼스널컬러 진단 및 스타일링제품 추천 시스템



전은희

윤나연

김성웅

지도교수 감진규 교수님

목 차

1.서론	1
1.1. 연구 배경	1
1.2. 기존 문제점	2
1.3. 기존 연구모델	2
1.4. 연구 목표	3
2. 연구 배경	3
2.1. 데이터 수집-crawling, augmentation, oversampling	3
3. 연구 내용	5
3.1. 데이터 전처리	5
3.1.1. White balance	6
3.1.2. Cut Face	7
3.2. 모델설계	8
3.2.1. ResNet50	8
3.2.2. VGG16, VGG19	10
3.3. 모델학습	11
3.3.1. multi-output	11
3.3.2. Transfer learning	11
3.3.3. FC(Fully Connected) Layers	11
3.3.4. method	12
3.4. 모델성능비교	13
3.5. 웹 설계 및 구현	15
4. 연구 결과 분석 및 평가	17

5. 결론 및 향후 연구 방향	19
6. 참고 문헌	19
7. 구성원별 역할 및 개발 일정	20

1. 서론

1.1. 연구 배경



그림1-계절 별 퍼스널컬러

퍼스널컬러란 사람과 **가장 어울리는 색상**을 찾는 색채학 이론이다. 개개인마다 가지고 있는 고유의 색에 따라 조화를 이루는 색이 다르며 어떠한 색으로 스타일링 하는가에 따라 개인의 인상을 다르게 만들수 있다. 이에 따라 어울리는 색조 화장품이나 옷, 장신구 등을 찾을 수 있다. 최근 퍼스널컬러 열풍이 불면서, 자신에게 잘 어울리는 고유한 색이 무엇인지 알고 싶어 하는 대중들의 니즈가 커졌고, 이를 진단해주는 업체들도 급격하게 생겨나고 있다. 컬러 전문가인 컬러리스트 자격증도 국가전력사업 중에 하나가 됐다.

[트렌드일기:MZ읽기] 퍼스널컬러로 나를 찾아요

승인 2021-10-29 09:08 신문게재 2021-10-29 10면



김지운 기자



트렌드일기:MZ읽기

최근 퍼스컬컬러 진단, MZ세대 사이 필수로 자리잡아
이력서 사진 배경을 선택할 때도 가장 중요한 요소



실시간 누

- 4시간전 대전
- 15시간전 [홍]
- 17시간전 한호
- 19시간전 추우
- 19시간전 [영]

그림2- 퍼스널컬러 열풍 기사[1]

또한, 최근 화장품 브랜드들도 퍼스널컬러에 따른 화장품을 판매할 만큼 퍼스널컬러는 화장품 산업의 중요한 대목이 되었다.



그림3- 실제 올리브영 홈페이지에 판매하는 퍼스널컬러 톤 별 화장품

1.2. 기존 문제점

퍼스널컬러는 분석을 희망하는 고객이 내방하면, 컨설턴트가 맨 얼굴과 손목 등의 피부에 컬러 천(드레이프 천)을 대어보고 비교하며, 가장 적합한 톤을 찾아내는 작업을 진행한다. 소요 시간은 평균 1시간, 가격은 10만원내외이다. 이렇게 오프라인으로 진행 할 경우 많은 비용과 시간이 소요된다. 코로나19와 언택트산업, 비대면의 가치가 더욱 중요시되고 있는 지금, 퍼스널컬러 분석 역시 그 시류에 맞게 변화하고 진화해야 한다.

또한 기존에 존재하는 퍼스널컬러 진단 앱은, 톤 분석만 해줄 뿐 스타일링 추천은 해주지 않는다. 자신에게 맞는 옷과 화장품을 고르기위해 퍼스널컬러를 진단받는 만큼 스타일링은 퍼스널 컬러 진단의 궁극적인 목표이므로 이 기능을 추가하기로 했다.

1.3. 기존 연구모델

고려대 세종캠퍼스 학생들이 제작한 퍼스널컬러 분류기가 존재한다.[6] 이는 웜/쿨만 판별하는 모델을 만들었지만 본 졸업과제는 웜,쿨뿐만아니라 계절, 그리고 성별까지 판별하는 모델을 개발하였다. 이들은 간단한 cnn모델을 이용했으며 학습 정확도는 약 94%정도이다.



그림4-고려대 학생들의 퍼스널컬러 분류기

1.4. 연구 목표

본 졸업과제는 각 퍼스널컬러 계절별 대표 연예인으로 이미지 학습을 시킨 딥러닝 모델을 통해 퍼스널컬러 진단 및 스타일링 추천 시스템을 웹으로 구현하고자 한다.

2. 연구 배경

2.1. 데이터 수집-crawling, augmentation, oversampling

안면 이미지 데이터를 수집하기 위해 웹 crawling을 이용하였다.[2] 기존에 퍼스널 컬러가 알려진 대표 연예인의 이미지를 google상에서 수집한 후 얼굴이 가려진 이미지, 해당 연예인이 아닌 이미지 등 잘못된 데이터들을 1차적으로 수동으로 제거하였다. 그 후 정확한 모델링을 위해 랜드마크를 이용해 얼굴을 인식한 후 안면 이미지만을 잘라내도록 했다.



그림5- crawling한 원본 이미지(좌)와 안면 이미지만을 추출한 이미지(우)

크롤링을 이용하여 확보한 데이터셋은 계절별로 약 50장에서 300장으로 수량에 있어서 한계가 존재했다. 때문에 데이터 전처리 과정을 거친 후 augmentation과 oversampling을 이용하여 최대한 많은 데이터셋을 확보할 수 있도록 하였다.

2.1.1 Augmentation

augmentation은 parameter 값들을 조절하여 이미지를 회전, 확대, 축소시켜 훈련시킬 때 다양한 방향으로 된 이미지를 적용할 수 있도록 해준다. parameter값으로는 회전시킬 범위를 정해주는 rotation_range, 이미지를 이동시킬 범위를 정해주는 width_shift_range와 height_shift_range, 확대 혹은 축소시킬 범위를 정하는 zoom_range, 뒤집을지 여부를 정하는 horizontal_flip, vertical_flip이 있으며 각각을 적용할 경우 아래와 같은 결과를 얻을 수 있다.




그림6 -이미지에 augmentation을 적용한 결과 예시이다.

본 과제에서 적용한 parameter값들은 아래의 표와 같다.

표1-augmentation시 적용한 parameter값. rotation_range는 이미지를 회전시킬 범위, width_shift_range와 height_shift_range는 이미지를 좌우 또는 상하로 이동시킬 범위, zoom_range는 이미지를 확대 혹은 축소할 범위, horizontal_flip과 vertical_flip은 이미지를 좌우 혹은 상하로 뒤집을 여부를 의미한다.

rotation_range	25
width_shift_range/height_shift_range	0.05
zoom_range	0.2
horizontal_flip	True
vertical_flip	False

2.2.2 Oversampling

본 과제에서 사용한 데이터셋의 개수는 아래 표와 같다.

표2-훈련에 사용한 데이터셋 수로 train시 사용한 이미지와 validation시 사용한 이미지 수를 합친 수이다.

	Male	Female
Spring	39	376
Summer	154	245
Fall	108	333
Winter	178	206

표에서 확인할 수 있듯이 계절 및 성별별로 이미지의 수의 불균형이 크게 발생하였다. 이로 인해 데이터 불균형을 조정하기 위해 데이터셋의 양을 증폭시키는 oversampling을 이용하게 되었다.




그림7-Oversampling이해도. 적은 양의 dataset을 copy하여 양을 증폭시킨다.

3. 연구 내용

3.1. 데이터 전처리

퍼스널 컬러는 사람의 피부색, 눈, 머리카락 색이 영향을 미치기 때문에 사진이 찍힌 당시의 조명에 의해 판별이 달라질 수 있다. 이 때문에 우리는 카메라의 기능 중 원래의 색과 거의 같도록 색을 보정해 주는 화이트 밸런스를 이용하기로 하였다. 또한 훈련 시 얼굴 이미지가 아닌 배경의 영향을 덜 받기 위해 안면을 인식하여 얼굴 이미지만을 추출하였다.

3.1.1. White balance

이미지가 찍힌 당시 조명의 영향을 덜 받기 위해 모델을 훈련하기 전에 색온도를 조절하는 카메라 기법 중 하나인 화이트 밸런싱을 적용하였다. white balance는 조명에 영향을 받은 색온도를 조절하기 때문에 각 색의 평균치에 light값을 빼낸 수치를 이용하도록 하였다. 아래 수식은 각 색온도에 적용한 계산을 간단히 수치화 하여 쓴 식이다.

$$\chi_n = \chi_n - (\chi * light / 100 * 1.1)$$

본 과제에서 화이트 밸런싱은 OpenCV를 사용하여 이미지의 light값, 색온도 값을 추출하여 사용[3]하였으며 결과적으로 그림5에서 확인할 수 있듯이 색감이 조정된 이미지를 얻을 수 있었다.



그림8- 화이트 밸런싱을 적용한 전(좌)과 후(우)의 이미지 변화

하지만 추후 훈련 데이터셋에 모든 전처리를 끝낸 후 모델에 훈련시켰을 때 화이트 밸런싱을 적용한 데이터셋보다 적용하지 않은 데이터셋의 validation 정확도가 더 높게 나왔다.

표3-화이트 밸런싱을 적용한 후와 적용하지 않은 경우 vgg모델에서 훈련했을 때 각각의 accuracy

	white balance 적용		white balance 미적용	
	train set	validation set	train set	validation set
Evaluate accuracy	0.9935	0.7943	0.9903	0.9085

화이트 밸런싱을 적용한 후와 적용하지 않은 데이터셋을 비교한 결과 그림8에서 확인할 수 있듯이 몇몇의 이미지에서 화이트 밸런싱이 적용된 후에 진한 노란빛, 분홍빛 등 보편적인 사람의 피부색이 아닌 방향으로 색보정이 적용된 것을 확인할 수 있었다. 이는 화이트 밸런싱을 기존의 색온도를 더욱더 명확하게 만드는 방향으로 구현하였기 때문에 적용이 실패한 것이라 추측하였고 결과적으로 화이트 밸런싱을 제외한 데이터셋을 이용하기로 결정하였다.




그림9- 화이트 밸런싱이 적용되기 전(좌)과 적용된 후(우)의 모습.

3.1.2. Cut Face

배경을 제외한 안면 이미지만을 이용하여 훈련하기 위해 데이터셋의 얼굴을 인식한 후 안면 이미지만을 자르는 전처리를 했다. 안면을 랜드마크킹하여 얼굴을 인식하기 위해 높은 정확도를 보이는 dlib을 이용하여 구현하였으며 얼굴 윤곽과 눈, 코, 입을 찾는 총 68개의 랜드마크를 찾도록 구현했다.




그림10- 68개의 랜드마크를 표시한 그림

랜드마크를 이용하여 얼굴 윤곽의 left, top, right, bottom의 4가지의 좌표 값을 이용해 rectangle을 그려 안면 이미지만을 추출하도록 했다.[5] 이미지가 다양한 크기로 구성되어 있기 때문에 동일한 크기의 이미지로 변환하기 위해 resize를 이용하였으며 최종적으로 width가 128로 동일한 데이터셋을 확보하였다.




그림11- 크롤링하여 얻은 원본 이미지(좌)와 안면인식 후 최종적으로 얻은 이미지(우)

3.2. 모델설계

모델 설계 과정 중 먼저 어떤 형태의 모델을 사용할지 결정하는 문제가 있었다. knn, resnet, vgg 모델을 시도해보면서 정확도를 비교하고 본 졸업과제 취지에 가장 적합한 모델을 판단하여 선택하였다.

3.2.1. ResNet50

ResNet은 Residual neural network의 모델로, 인풋 값들이 중간에 특정 레이어들을 모두 거치지 않고 한 번에 건너 뛰기도 한다. ResNet-50은 이러한 컨볼루션이 50개 계층으로 구성되어있는 신경망이다. 필자는 tensorflow.keras에 있는 ImageNet에서 사전학습이 진행된 resnet50을 불러와 모델을 구성하였다.




그림12- resnet50 구성도 일부

Evaluate 결과 상대적으로 loss는 높고 accuracy가 낮게 나왔다. 그래프로도 validation accuracy가 낮은 것을 확인할 수 있다.

```
[ ] model.evaluate(train_generator)
```

```
58/58 [=====] - 21s 368ms/step - loss: 0.3683 - accuracy: 0.8631
[0.36827096343040466, 0.8630660176277161]
```

```
[ ] model.evaluate(validation_generator)
```

```
19/19 [=====] - 1s 43ms/step - loss: 2.3027 - accuracy: 0.3699
[2.302696943283081, 0.36986300349235535]
```

그림13- resnet의 성능평가 결과. train dataset의 accuracy는 0.8631, validation dataset의 accuracy는 0.3699로 측정된 것을 확인할 수 있다. .

3.2.2. VGG16, VGG19

VGGNET은 CNN의 대표적 모델 중 하나로, 16개의 Layer 로 이루어져 있으면 VGG16, 19개의 Layer로 이루어져 있으면 VGG19이다. VGGNET도 마찬가지로 ImageNet에서 사전학습된 tensorflow의 keras에서 불러와 사용하였다.




그림14- vgg16 구성도




그림15- vgg19 구성도

Evaluate 결과 상대적으로 높은 accuracy와 낮은 loss를 보였으며 VGG16에서 상대적으로 더 높은 정확도를 얻을 수 있었다.

표4-vgg16과 vgg19의 accuracy

		VGG16	VGG19
Evaluate accuracy	train dataset	0.9350	0.8715
	validation dataset	0.7105	0.6755

3.3. 모델학습

모델학습은 Google Colab상에서 진행하였으며 이미지처리를 위해 tensorflow를 활용하였다.

3.3.1. multi-output

기존에 계절 톤만 output으로 출력되는 모델을, 계절과 성별모두 출력되는 모델로 설정하였다. 위와 같이 tensorflow.keras에 있는 vgg16을 불러와 input과 output 2개(성별2개, 계절4개)가 출력되도록 확장 하였다.

3.3.2. Transfer learning

전이학습은 하나의 작업을 위해 훈련된 모델을 유사 작업 수행 모델의 시작점으로 활용하는 딥러닝 접근법이다. 이미 훈련된 널리 쓰이는 모델을 재사용함으로써 훈련 시간과 연산 리소스를 이용하여 모델을 훈련할 수 있다는 장점이 있다. 본 연구는 vgg16의 16 Layer 중 1-7 Layer 까지는 freezing(trainable=false)을 시켜 overfitting을 예방하였다. 나머지 8-16 Layer는 fine-tuning(trainable=true)을 진행하였다.

3.3.3. FC(Fully Connected) Layers

사전학습 된 VGGNET의 feature로 퍼스널컬러와 성별을 분류하기 위해 FC Layer를 구성하였다. FC Layer는 flatten, dense(activation=relu)로 구성되어 있으며, overfitting을 방지하기 위하여 dropout(0.5%) layer도 추가하였다.




그림16- 3.3.1, 3.3.2, 3.3.2 적용한 모델구성도

3.3.4. method

표5 - 파라미터

Hyper Parameter	설정 값
Learning Rate Scheduler	step_decay, verbose=1
step_decay	start = 0.0005 drop = 0.8 epochs_drop = 15.0
loss 함수	categorical_crossentropy
optimizer	Adamax

LearningRateScheduler는 epoch에 따라 학습률을 조정하는 callback이다. 인자로 받는

schedule은 epoch index를 조정할 수 있는 function으로, 본 졸업과제는 epoch 구간(step) 마다 일정한 비율로 감소시켜주는 방법인 step_decay를 이용하여 0.0005에서 시작한 learning rate를 15 epoch 마다 80%씩 감소시켰다.




그림17- step decay그래프

3.4. 모델성능비교

본 졸업과제는 confusion matrix를 구해 다른 모델들의 accuracy, precision, recall, f1 score 수치를 정량적으로 비교해보았다.




그림18-평가 label(좌) 과 score별 공식(우)




그림19-본 졸업과제(vgg16) confusion matrix

표6- 모델 별 score(계절)

model	score	accuracy	precision	recall	f1
resnet50		0.3576	0.4796	0.3576	0.3157
vgg19		0.6755	0.6722	0.5761	0.5474
Ours(vgg16)		0.9006	0.9029	0.9006	0.9003

표7- 모델 별 score(성별)

model	score	accuracy	precision	recall	f1
resnet50		0.7947	0.8052	0.7947	0.7660
vgg19		0.9403	0.9405	0.9403	0.9382
Ours(vgg16)		0.9767	0.9769	0.9767	0.9766

score를 종합해 보았을 때, vgg16을 사용한 본 졸업과제(Ours)가 성능점수가 가장 높았다.

3.5. 웹 설계 및 구현

웹 애플리케이션을 구현하기 위해 Python과 JavaScript, css 언어와 flask를 사용하였다. [7]훈련시킨 모델을 웹 상에서 이용하기 위해서 vgg모델을 HDF5형태의 파일로 저장하여 사용하였으며 이용자가 이미지를 업로드하는 방식으로 서비스를 제공하기 때문에 flask를 이용하여 이미지를 받도록 하였다. 그 후 해당 파일의 얼굴을 인식하여 안면만을 추출하는 전처리를 거친 후 모델을 활용하여 결과를 도출해내는 과정을 거쳤다.




그림20-도식화 한 전체적인 구조이다.

웹 상에서 퍼스널 컬러 뿐 아니라 해당 컬러에 해당하는 분위기와 코드를 추천해 주도록 설계하였다. 추가적으로 여성일 경우 색조 화장의 best, worst조합[4]을, 남성일 경우 추천하는 염색 조합을 보여주도록 하였다.

What is your personal color?



푸른기 있는 색이 주를 이루며 선명하고 강해요. 도시적이고 도도한 이미지를 지녔어요!



Worst Make Up
-오렌지와 같이 주황빛이 도는 색상의 메이크업
-브라운 색상의 아이라이너

코디추천

대배꼽있는 길러가 좋아요. 셋업수트도 잘 어울립니다!



그림21- 퍼스널 컬러를 진단한 후 보여지는 화면 중 하나로 predict결과가 겨울쿨톤인 여성일 때 보여지는 화면이다.

4. 연구 결과 분석 및 평가

VGG, ResNet을 사용하여 모델을 생성한 결과 화이트 밸런싱을 사용하지 않고 훈련시킨 VGG16에서 가장 높은 accuracy를 보였다.

```
add_model.evaluate(three_way(train_generator), steps=len(train_generator))
add_model.evaluate(three_way(valid_generator), steps=len(valid_generator))
```

```
71/71 [=====] - 9s 121ms/step - loss: 0.0401 - output1_loss: 0.0292 - output2_loss: 0.0108 - output1_acc: 0.9903 - output2_acc: 0.9965
171/171 [=====] - 5s 29ms/step - loss: 0.7576 - output1_loss: 0.3684 - output2_loss: 0.3692 - output1_acc: 0.9085 - output2_acc: 0.9449
```

그림22- 화이트 밸런싱을 적용하지 않은 후 vgg모델에서 훈련했을 때 정확도로 train set의 정확도는 약 0.99, validation set의 정확도는 약 0.90임을 확인할 수 있다.




그림23- 해당 모델에서의 training and validation accuracy와 loss그래프

위의 그림22과 그림23를 보면 최종 결과로 나온 validation set의 정확도는 0.90-0.94사이로 나타난다. 그러나 loss는 수렴하지 않는 것을 확인할 수 있다. 이는 훈련에 필요한 양질, 다량의 데이터셋을 확보하지 못한 점이 원인으로 추측된다.

최종적으로 그림24와 같이 사용자의 퍼스널컬러를 측정하고 코디, 메이크업 등을 추천하는 서비스를 구현하였다.

What is your personal color?



가을 웜톤은 차분하고 무거운 분위기의 부드러운 컬러로 전반적으로 고급스럽고 강하면서도 편안 느낌을 가지고 있어요! 부드러운 인상 속에 우아한 분위기를 풍겨서 어른스럽고 차분한 이미지를 가지고 있어요

염색컬러추천
-채도가 낮고 어두운 계열
-다크브라운, 레드브라운, 모카블론드



코디추천

대비감을 강하게 주기 보다는 은은한 톤으로 연출하는게 좋아요




그림24- 퍼스널 컬러를 진단한 후 보여지는 화면 중 하나로 predict결과가 가을웜톤인 남성일 때 보여지는 화면

5. 결론 및 향후 연구 방향

우리는 퍼스널컬러 분류를 위해 CNN 모델중 VGGNET 이미지 분류 알고리즘을 이용하였다. 학습 데이터셋은 우리에게 알맞은 것이 따로 존재하지 않아 직접 마련할 필요가 있었기에 웹 크롤링과 직접 파이썬으로 OpenCV를 활용하여 가공하였다.

이로써 데이터 수집부터 전처리, 모델 설계 및 학습까지 딥러닝 과정 전체를 경험해볼 수 있었다. 물론 깔끔하게 가공된 양질의 대용량 데이터셋의 부재와 화이트밸런싱 문제로 퍼스널컬러 전문가에게 직접 진단을 받는 것 만큼의 정확도를 가질 순 없겠지만 본 과제의 원래 목표에 맞게 가정에서 간편하게 자신의 퍼스널컬러를 확인해 봄으로써 시간과 돈을 절약해줄 수 있음에 의미를 두고자 한다. 하지만 앞서 말한 대용량의 양질의 데이터셋과 화이트밸런싱 문제 해결 그리고 그를 받쳐줄 수 있는 GPU 가 존재한다면 거의 전문가의 진단 결과와 같은 정확도를 보일 것이라 생각한다.

6. 참고 문헌

- [1]중도일보, Available: <http://m.joongdo.co.kr/view.php?key=20211028010005734>
- [2] tistory, Available: <https://chococookiee.tistory.com/49?category=956795>
- [3]LeeLAB(2020.Oct 5), Available: https://www.leelab.co.kr/bbs/board.php?bo_table=python&wr_id=105&sst=wr_hit&sod=desc&sop=and&page=4&device=pc
- [4] bnt뉴스, Available: <https://www.hankyung.com/life/article/201509198120k>,
- [5] Github, Available: <https://github.com/tribbless/helpmemakeupmirror>
- [6]Youtube, Available: <https://www.youtube.com/watch?v=GOp4MVE3BnE>
- [7] Github, Available: <https://github.com/krishnaik06/Deployment-Deep-Learning-Model/blob/master/app.py>

7. 구성원별 역할 및 개발 일정

표8- 구성원별 역할

학번	성명	구성원별 역할
201824533	윤나연	data crawling 및 모델 구축, 웹 구축
201524429	김성웅	모델 구축 및 정확도 조정, 데이터셋 전처리
201824574	전은희	데이터셋 전처리 및 웹 구축, 모델 정확도 조정

표9- 개발일정

6 월				7 월				8 월					9 월				
1	2	3	4	1	2	3	4	1	2	3	4	5	1	2	3	4	
머신러닝 스터디																	
	학습 데이터 생성																
기본모델작성																	
				기본모델 평가													
				진단 알고리즘 개발													
						중간 보고서											
							데이터셋 구축										
								UI 및 웹 설계									
												정확도 조정					
														평가			
														최종 보고서			
																시연 준비	